



化工学报
CIESC Journal
ISSN 0438-1157, CN 11-1946/TQ

《化工学报》网络首发论文

题目: 基于深度学习的气液固三相反应器图像分析方法及应用
作者: 黄正梁, 王超, 李少硕, 杨遥, 孙婧元, 王靖岱, 阳永荣
收稿日期: 2019-10-23
网络首发日期: 2019-10-28
引用格式: 黄正梁, 王超, 李少硕, 杨遥, 孙婧元, 王靖岱, 阳永荣. 基于深度学习的气液固三相反应器图像分析方法及应用. 化工学报.
<http://kns.cnki.net/kcms/detail/11.1946.tq.20191026.1237.004.html>



网络首发: 在编辑部工作流程中, 稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定, 且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式 (包括网络呈现版式) 排版后的稿件, 可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定; 学术研究成果具有创新性、科学性和先进性, 符合编辑部对刊文的录用要求, 不存在学术不端行为及其他侵权行为; 稿件内容应基本符合国家有关书刊编辑、出版的技术标准, 正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性, 录用定稿一经发布, 不得修改论文题目、作者、机构名称和学术内容, 只可基于编辑规范进行少量文字的修改。

出版确认: 纸质期刊编辑部通过与《中国学术期刊 (光盘版)》电子杂志社有限公司签约, 在《中国学术期刊 (网络版)》出版传播平台上创办与纸质期刊内容一致的网络版, 以单篇或整期出版形式, 在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊 (网络版)》是国家新闻出版广电总局批准的网络连续型出版物 (ISSN 2096-4188, CN 11-6037/Z), 所以签约期刊的网络版上网络首发论文视为正式出版。

研究论文

DOI: 10.11949/0438-1157.20191255

基于深度学习的气液固三相反应器图像分析方法及应用

黄正梁^{1,3}, 王超^{1,3}, 李少硕^{1,3}, 杨遥^{1,3}, 孙婧元^{1,3}, 王靖岱^{1,2}, 阳永荣^{1,2}

(¹浙江省化工高效制造技术重点实验室, 浙江 杭州 310027; ²浙江大学化学工程国家重点实验室, 浙江 杭州 310027; ³浙江大学化学工程与生物工程学院, 浙江 杭州 310027)

摘要: 气液固三相反应器中复杂的颗粒背景给流动参数的图像检测带来巨大挑战。发展了一种基于深度学习的气液固三相反应器图像分析方法, 包括采集图像、制作训练集、建立图像识别模型和提取流动参数等四个步骤。采用全卷积神经网络, 在学习率为 0.005、训练次数为 2000 次、训练集大小超过 400 张图像的条件下, 图像识别误差小于 5%。利用该方法可以获取三相反应器中局部相含率(气相分数和液相分数)及其空间分布、时间序列等信息, 再采用时域分析、频率分析、小波分析等分析方法提取二次参数, 可用于流型识别、压降预测和气液分布的均匀性判别等。将该方法用于涓流床中流动参数的检测, 结果表明, 局部液相分数的时间序列信号及其功率谱、概率密度分布均能清晰地区分涓流、脉冲流、鼓泡流等典型流型; 时间序列信号的均值、标准差、极差和概率密度分布曲线半峰宽等特征参数可用于确定流型边界; 平均液相分数可以用于预测涓流区的压降, 计算值与实验测量值的平均相对偏差约为 15%; 液相分数空间分布的标准差可用于表征涓流床中不同流型的气液分布均匀性。该方法为气液固三相反应器的研究提供了新的工具。

关键词: 多相流; 深度学习; 神经网络; 成像; 涓流床; 相含率

中图分类号: TQ021.9

文献标志码: A

Development and application of image analysis method based on deep-learning in gas-liquid-solid three-phase reactor

HUANG Zhengliang^{1,3}, WANG Chao^{1,3}, LI Shaoshuo^{1,3}, YANG Yao^{1,3}, SUN Jingyuan^{1,3},
WANG Jingdai^{1,2}, YANG Yongrong^{1,2}

(¹ Zhejiang Provincial Key Laboratory of Advanced Chemical Engineering Manufacture Technology, Hangzhou 310027, Zhejiang, China; ² State Key Laboratory of Chemical Engineering, Zhejiang University, Hangzhou 310027, Zhejiang, China; ³ College of Chemical and Biological Engineering, Zhejiang University, Hangzhou 310027, Zhejiang, China;)

Abstract: In gas-liquid-solid three-phase reactors, the great challenges for image detection of flow parameters have been caused by the complex background with particles. In this work, an image analysis method based on deep learning for gas-liquid-solid three-phase reactors was developed, including four steps, namely capturing images, generating a training set, establishing the model and extracting flow parameters. The full convolutional neural network algorithm was chosen to build the identification model, and when the learning rate was set as 0.005, the number of epochs was set as 2000 and the training set size was set as 400 images in this model, the identification error of the model is less than 5%. The flow parameters such as local phase fractions (gas fraction and liquid fraction) and its spatial distribution, time series signals were obtained by the method. Then time domain analysis, frequency analysis, wavelet analysis and other analysis methods were used to extract the quadratic parameters from the spatial distribution and time series signals. And the quadratic parameters could be used to identify flow regimes, predict pressure drop and detect the uniformity of gas-liquid distribution. Furthermore, the method was

applied to the detection of flow parameters in a trickle bed. The results showed that the time-domain variation, power spectrum density and probability density distribution of liquid fractions were used to distinguish the trickle flow, pulse flow and bubble flow. Meanwhile, the flow regime boundary was detected by characteristic parameters such as mean, standard deviation, range and half-width of probability density distribution curve of liquid fractions. The pressure drop in the trickle flow regime was predicted by the average liquid fraction, and the average relative deviation between the theoretical and experimental measurements was about 15%. In addition, the standard deviation of liquid fractions in the spatial distribution was used to detect the uniformity of gas-liquid distribution of different flow regimes in the trickle bed. This method provides a new tool for the research of gas-liquid-solid three-phase reactors.

Key words: multiphase flow; deep-learning; neural networks; imaging; trickle bed; phase fraction

收稿日期: 2019-10-23 修回日期: 2019-10-24

通信作者: 王靖岱 (1974—), 男, 教授, wangjd@zju.edu.cn

第一作者: 黄正梁 (1982—), 男, 助理研究员, huangzhengl@zju.edu.cn

基金项目: 国家自然科学基金项目 (91834303); 国家杰出青年科学基金项目 (21525627); 国家自然科学基金创新研究群体项目 (61621002)

引言

涓流床、三相鼓泡床、三相移动床等气液固三相反应器广泛应用于石油和化学工业^[1-2]。气液固三相反应器中不同操作条件下会出现不同的流动行为^[3]，对反应器中的流动和传递产生显著影响^[4]。流型、相含率及其分布等流动参数地准确测量对气液固三相反应器的设计和优化具有重要意义。

针对气液固三相反应器中的流动行为，常用的检测方法包括目测法^[5-7]、高速摄像法^[8-10]、压降法^[11-12]、声信号检测法^[13]、电导探针法^[14]、电子断层扫描^[15-16]、X 射线成像^[17]、磁共振成像^[18-19]和伽马射线断层扫描^[20]等。其中，目测法和高速摄像法等可视化方法常用于验证其他检测方法的准确性^[21]，然而可视化方法通常只能进行定性分析。有学者将单层圆柱型规整填料均匀地固定在两块透明板之间，制成一种特殊结构的二维床，采用高速摄像法研究了规整填料中气泡的破碎、聚并行为^[9-10]。他们使用的圆柱型规整填料间距较大，与实际反应器存在较大差异。在实际工业装置中，球形、齿球形、三叶草形等不同形状的催化剂颗粒紧密堆积在反应器中，复杂的颗粒背景使拍摄得到的图像中气液两相之间的灰度差异非常小，给定量分析带来了极大的挑战。

近年来，以深度学习为代表的图像处理方法取得了重大突破，使得从背景复杂的图像中精确提取目标信息成为可能^[22-25]。深度学习作为分析数据的机器学习方法之一，其源于神经学研究的启示，能够像大脑一样通过组合低层特征形成更加抽象的高层特征^[26]。在深度学习的起源阶段，在神经元结构和工作原理的启发下，构建了 M-P 模型、感知机等结构，奠定了神经网络模型的基础^[27]。在其发展过程中，误差反向传播（BP）算法在正向传播的基础上，增加了误差的反向传播过程，促成了神经网络的崛起，但其容易出现梯度弥散现象^[28]。直到 2006 年，Hinton 等^[29]开创性地提出了深度学习的概念及模型训练方法，即通过无监督的学习方法逐层训练，再使用有监督的反向传播算法进行调优，打破了 BP 神经网络发展的瓶颈。随后在受限玻尔兹曼机、自动编码器、稀疏编码和卷积神经网络等多种典型算法的基础上，深度学习技术被广泛应用于语音、图像和自然语言处理等领域^[30]，尤其是图像中对象和区域的检测、分割和识别等^[24]，例如交通标志识别^[31]、医学图像分析^[32]、人脸识别^[33]和人体姿势预测^[34]等。因此，本文将深度学习方法用于气液固三相反应器中图像分析，期望定量地获取三相体系中的相含率及其分布、流型等流动参数，为气液固三相反应器的研究提供新的工具。

1 测量原理及方法

1.1 测量原理

基于深度学习的气液固三相反应器图像分析方法的原则流程如图 1 所示，包括采集图像、制作训练集、建立图像识别模型、提取流动参数等 4 个步骤。

步骤（1）——提取图像。在透明的气液固三相反应器模拟实验装置中（一般用二维床或矩形床），利用高速相机获取不同操作条件下的图像，典型的图像如图 2(a)所示。

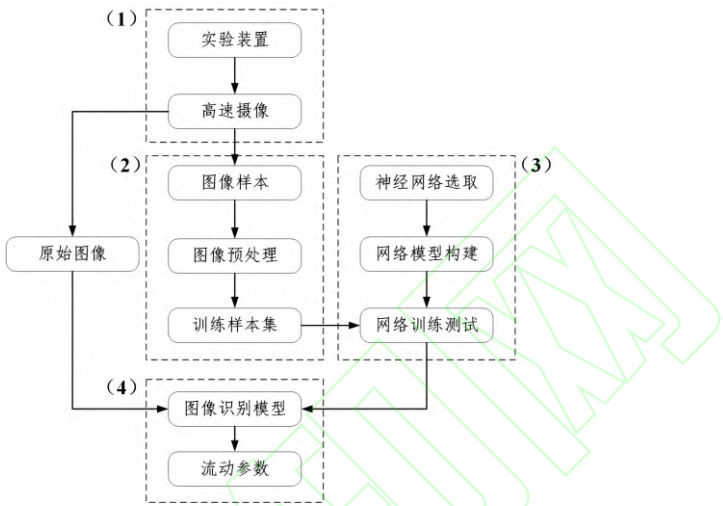


图 1 基于深度学习的气液固三相反应器图像分析流程

Fig. 1 The procedure of image analysis method based on deep-learning in gas-liquid-solid three-phase reactors

步骤（2）——制作训练集。随机选择部分原始图像作为样本图像，采用 Photoshop CS5 中的光标绘制样本图像中的气液边界，然后用白色填充气相以增加气相和液相之间的灰度差异，可以获得如图 2(b)所示的分割图像；将分割图像转换为灰度图像，并通过阈值分割程序（灰度阈值取 250）进一步处理，得到如图 2(c)所示的二值化图像，其中白色区域为气相。采用上述方法处理所有样本图像，将样本图像及其对应的二值化图像合并为训练集、验证集和测试集，三者比例为 3:1:1。

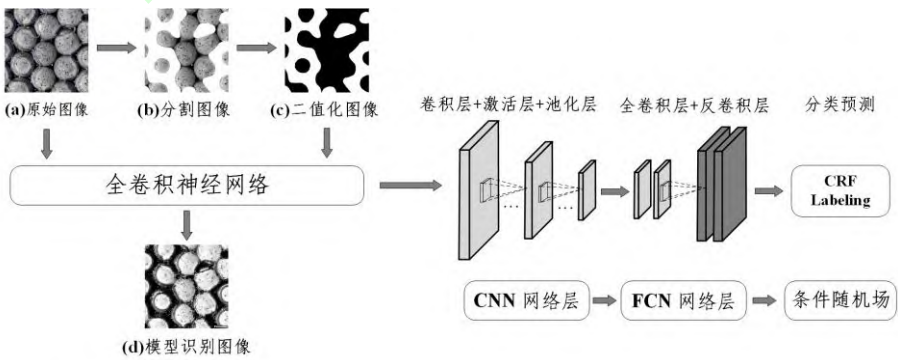


图 2 图像的典型处理过程

Fig. 2 Typical processing of the original images

步骤（3）——建立图像识别模型。使用 MATLAB 神经网络工具箱，以图 2 所示的全卷积神经网络（FCN）算法为基础构建神经网络模型。全卷积神经网络由 CNN 网络层、FCN 网络层和条件随机场等三部分组成。其中，CNN 网络层包括卷积层、激活函数层和池化层，在 5 个卷积层中，采用 5×5 的卷积核，步长为 1；采用随机初始化权重及误差反向传播方法进行网络的训练和网络层的连接；采用 2×2 的核进行最大池化操作；利用 Relu 函数克服梯度消失问题。FCN 网络层对输入图像的特征进行全卷积操作并计算 Softmax 分类的代价函数，采用均值操作融合对应图像的特征，并进行像素点的预测，最后通过反卷积上采样操作将图像恢复至输入尺寸。条件随机场主要是用于进一步提高学习精度。

模型建立过程中，首先将原始图像和其二值化图像（见图 2(a)和 2(c)）输入全卷积神经网络模型，经过模型内部的训练学习，得到图 2(d)所示的识别结果^[35-37]，计算其与图 2(c)所示的二值化图像之间的偏差，当偏差大于设定值时，调整模型参数继续训练；当偏差小于设定值时，认为图像识别模型已构建完成。

步骤（4）——提取流动参数。采用所建立的图像识别模型对原始图像进行分析，获得局部相含率（气相分数和液相分数）及其空间分布、时间序列等信息。其中，位于液相区的像素点被识别为 0，位于气相区的像素点被识别为 1，局部液相分数等于被识别为 0 的像素点之和与总像素点的比值，局部气相分数等于被识别为 1 的像素点之和与总像素点的比值。进一步，如图 3 所示，采用时域分析、频谱分析、小波分析等现代分析方法，对局部相含率的时间序列信号进行分析，获得均值、标准差、特征峰位置、特征峰强度等二次参数，可以与压降、流型、流型转变等流动参数进行关联；对局部相含率的空间分布数据进行分析，获得方差、标准差、概率分布半峰宽等二次参数，可用于表征相含率空间分布的均匀性及其随时间的变化特征。

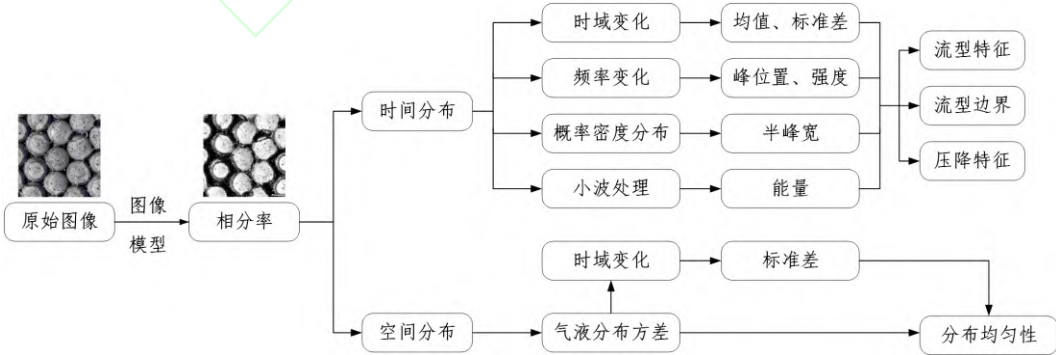


图 3 气液固三相反应器图像分析方法提取的流动参数

Fig. 3 Flow parameters extracted by image analysis method in gas-liquid-solid three-phase reactors

1.2 模型参数优化

使用全卷积神经网络模型建立图像识别模型的过程中，学习率、训练次数、训练集大小是非常重要的模型参数，与模型预测准确率密切相关²⁵。不同学习率下图像识别模型的训练准确率随训练次数的变化如表 1 所示，当学习率从 0.0001 增大到 0.01 时，模型的收敛速度和训练准确率明显提高，且在学习率为 0.005 时达到最佳收敛效果。但当学习率大于 0.1 时，模型将不会收敛，且模型训练准确率仅为 60%。因此选择学习率为 0.005，以保证模型的训练精度并提高收敛速度。从表中还可看出，训练准确率随着训练次数的增加呈对数增长，当学习率为 0.005 且训练次数大于 2000 时，训练精度达到 95%。因此，训练次数选为 2000 能够保证训练准确率。

表 1 不同学习率下图像识别模型训练准确率随训练次数的变化

Tab. 1 Variations of the training accuracy of the model with the epochs at various learning rates

		训练准确率/%					
学习率	训练次数	50	100	200	500	1000	2000
0.0001		62.0	72.4	73.3	77.8	84.1	88.8
0.001		78.0	81.2	85.7	89.9	91.6	91.9
0.005		86.2	87.7	90.4	92.9	94.1	95.3
0.01		84.4	85.4	86.7	87.0	90.1	91.4
0.1		61.8	62.3	61.3	63.1	61.5	61.9

此外，训练集大小始终是决定深度学习模型预测准确率的关键因素，增大训练集能够降低模型预测值的平均相对偏差。本文分析了训练集大小对模型预测准确率的影响，通过将测试集输入模型得到模型预测值，与其对应的二值化图像进行对比，得到的平均相对偏差如表 2 所示。由表可知，平均相对偏差随训练集的增大逐渐减小，当训练集达到 350 张图像时，模型预测的平均相对偏差小于 5%，当训练集达到 400 张图像时，模型预测的平均相对偏差为 4.1%。因此，训练集包含 400 张图像可以保证训练准确率。综上，推荐的模型参数为：学习率 0.005，学习次数大于 2000，训练集包含超过 400 张图像。

表 2 图像识别模型的平均相对偏差对训练集大小的变化

Tab. 2 Variations of the average relative deviation of the model with the training set size.

训练集大小	50	100	150	200	250	300	350	400
平均相对偏差	20.6	16.0	12.1	9.1	7.2	5.1	4.4	4.1

2 图像分析法在三相体系中的应用

2.1 实验装置及方法




图4 气液固三相反应器冷模实验装置

1-水槽, 2-泵, 3-空气压缩机, 4-缓冲罐, 5-转子流量计, 6-电磁流量计, 7-固体料仓,
8-固体进料管, 9-气体分配器, 10-液体喷嘴, 11-矩形床, 12-光源, 13-高速相机, 14-图像采集系统

Fig. 4 Cold-model experimental system for a gas-liquid-solid three-phase reactor

1-Liquid tank, 2-Pump, 3-Air compressor, 4-Buffer tank, 5-Rotameter, 6-Electrmagnetic flowmeter,
7-Solids silo, 8-Solid feed tube, 9-Gas distributor, 10-Liquid nozzle, 11-Rectangular bed, 12-Light source, 13-
High-speed camera, 14- Image acquisition system

图4所示为气液固三相反应器冷模实验装置, 由矩形床、固体料仓、空气和供水系统、测量系统组成。其中矩形床由两个平行的玻璃板制成, 长100 mm, 高600 mm, 两块板之间的宽度为38 mm。不锈钢制成的固体料仓安装在矩形床上方500 mm处, 以确保颗粒的连续流动和床层上部的气密性。料仓通过直径为35 mm的固体进料管与矩形床连接, 固体进料管伸入床层120 mm。为了保证气液固的均匀分布, 气体分配器安装在固体进料管出口上方100 mm处, 两个连续液体喷嘴(BB1/8-SS, 喷嘴孔径2.0mm)安装在气体分配器和固体进料管的出口之间。其中, 分布器为多孔分布板, 孔径为1 mm, 正三角形排布, 开孔率为2.94%。

实验采用压缩空气、水和陶瓷球颗粒作为模拟介质。陶瓷球的主要成分为 SiO_2 , 直径6 mm, 液固接触角为 42.9° 。采用转子流量计(LZB-15)测量气相流量, 用电磁流量计(LDG-SUP)测量液相流量, 用电子天平(YP10K-1)测量固体质量。风速变化范围为 $0.007\sim 0.139\text{ m}\cdot\text{s}^{-1}$, 液速变化范围为 $0.003\sim 0.033\text{ m}\cdot\text{s}^{-1}$ 。采用高速相机(Photron Fastcam Mini WX100, Japan)及Photron配套软件, 在固定拍摄窗口拍摄分辨率为 2048×2048 像素的图像, 拍摄区

域大小为 20 mm×20 mm，位于气体分布器下方 500 mm 处。实验中使用的光源是 LED 背光源，光强度为 4000 cd。使用尼康相机自动对焦镜头（AF 50 / 1.8D）。采集速率设置为每秒 50 帧，曝光时间为 1/1000 s，采集时间设置为 30 s。

实验过程中固体颗粒不动，气液两相并流向下。在气速保持恒定的条件下，增大液体流速，使流型从涓流先转变为脉冲流再转变为鼓泡流，用于考察图像分析方法在涓流床典型流型识别中应用的可行性。实验前需要对颗粒进行预润湿，将颗粒在水中浸渍 30 min，然后自然过滤 20 min，保证颗粒表面无自由水，即可获得预润湿的颗粒^[38]。每次改变操作条件后，系统需要运行 10 min 以达到新的稳态，再使用高速相机采集图像。

2.2 图像分析法在涓流床中的应用

气液并流向下涓流床在不同操作条件下会出现涓流、脉冲流、鼓泡流等典型流型。大多数工业涓流床在涓流-脉冲流的转变边界附近操作，可以得到较高的传质效率和催化剂利用率，同时又能够降低能耗^[4]。

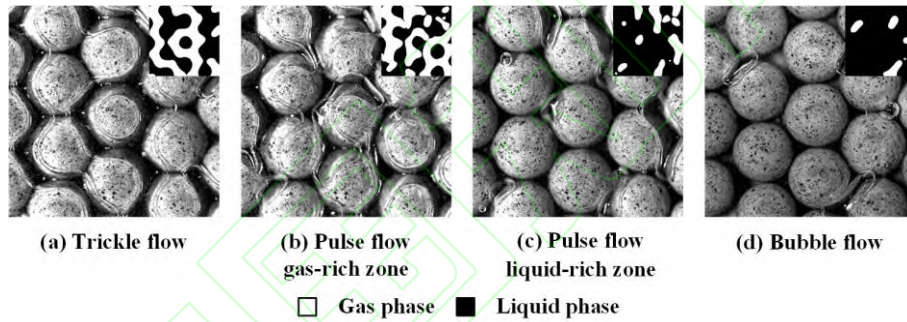


图 5 涓流床中 3 种典型气液流型

Fig. 5 Three typical gas-liquid flow behaviors in the trickle bed

(a) $u_G = 0.069 \text{ m}\cdot\text{s}^{-1}$, $u_L = 0.003 \text{ m}\cdot\text{s}^{-1}$, (b) and (c) $u_G = 0.069 \text{ m}\cdot\text{s}^{-1}$, $u_L = 0.022 \text{ m}\cdot\text{s}^{-1}$, (d) $u_G = 0.007 \text{ m}\cdot\text{s}^{-1}$, $u_L = 0.028 \text{ m}\cdot\text{s}^{-1}$

本文采用高速摄像法获得的涓流床中典型流型的照片见图 5。当气速和液速较低时（ $u_G = 0.069 \text{ m}\cdot\text{s}^{-1}$, $u_L = 0.003 \text{ m}\cdot\text{s}^{-1}$ ）为涓流，如图 5(a)所示，此时气液相都是连续相，床层空隙主要被气相占据，液相仅以膜流的形式沿颗粒表面向下流动，同时较弱的气液相互作用难以破坏相界面，气液相界面清晰。当液速足够大时（ $u_L = 0.022 \text{ m}\cdot\text{s}^{-1}$ ），涓流转变为如图 5(b)所示的脉冲流。局部液体脉冲形成的频率增加，汇聚在一起形成大脉冲进而阻塞整个床层横截面，因此气相和液相均为半连续相，富气区和富液区交替向下流动。同时较强的气液相互作用能够破坏气液相界面，气液相界面变得模糊。当液速进一步增大且气速减小时（ $u_G = 0.007 \text{ m}\cdot\text{s}^{-1}$, $u_L = 0.028 \text{ m}\cdot\text{s}^{-1}$ ），脉冲流转变为如图 5(c)所示的鼓泡流。此时气相为分散相，液相为

连续相，尽管气液相互作用较强，但气相推动力难以破坏连续的液体流，气体以气泡的形式分散在连续液相中。

2.2.1 涓流床中流型识别

采用本文提出的基于深度学习的图像分析方法，从原始图像提取气相分数和液相分数及其时间序列信号，通过分析时间序列信号及其频谱和概率密度分布的特征来识别流型。

涓流床中 3 种典型流型下局部液相分数随时间的变化如图 6 所示。在涓流流型下，液相分数较小并且随时间无明显变化；在脉冲流流型下，液相分数增大并且呈周期性的剧烈波动，变化范围为 55%-75%；在鼓泡流流型下，气相以气泡的形式分散在连续液流中，液相分数进一步增大，当气泡通过时会出现液相分数较低的信号峰。可见，通过液相分数随时间的变化特征能够区分涓流床中 3 种典型流型。




图 6 涓流床中 3 种典型流型下局部液相分数随时间的变化

Fig. 6 Variations of local liquid fraction with time under three typical flow regimes in the trickle bed

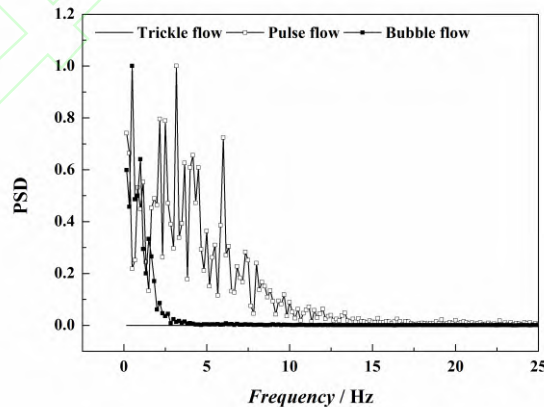


图 7 涓流床中 3 种典型流型下局部液相分数信号的功率谱图

Fig. 7 Variations of PSD of local liquid fractions under three typical flow regimes in the trickle bed

涓流床中 3 种典型流型下局部液相分数时间序列信号的功率谱如图 7 所示。在涓流流

型下，气液两相稳定向下流动，液相分数保持相对恒定，因此其功率谱图无明显的特征峰。在脉冲流流型下，富气区和富液区交替通过使得液相分数呈现周期波动，其功率谱图在 3 Hz 和 6 Hz 附近存在特征峰。而在鼓泡流中，气相以气泡的形式分散在液相中，气泡并聚对液相分数的扰动较小，因此其功率谱图的特征峰大多出现在极低的频率。可见，通过液相分数时间序列信号功率谱中特征峰位置也能够区分涓流床中 3 种典型流型。此外，还可以根据特征峰的频率和数量，定量描述气液两相的相互作用规律。

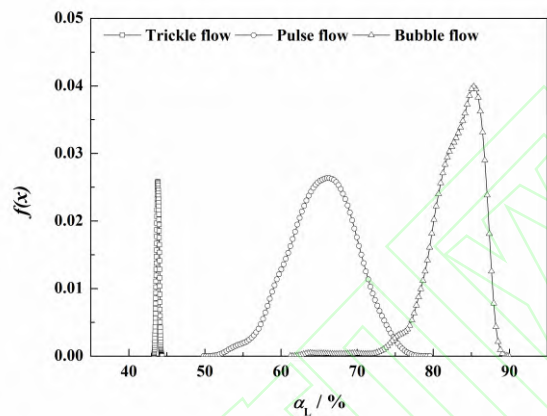


图 8 涓流床中 3 种典型条件下局部液相分数信号的概率密度分布曲线

Fig. 8 Variations of the probability density curve of liquid fractions under three typical flow regimes in the trickle bed

局部液相分数时间序列信号的概率密度曲线如图 8 所示，其在一定间隔内的积分可用于指示液相分数位于该区间内的概率。在涓流流型下，气液流动稳定，液相分数变化小，故其概率密度分布呈现出较窄的单峰分布。在脉冲流中，气液相互作用强烈，富气区和富液区的交替向下流动，液相分数在一定范围内剧烈波动，故其分布曲线呈现出较宽的单峰分布，且接近正态分布。在鼓泡流中，气泡的随机性导致液相分数使得其分布曲线呈现较宽的单峰左偏态分布。可见，通过液相分数时间序列信号的概率密度曲线分布特征也能区分涓流床中 3 种典型流型。

表 3 涓流床中 3 种典型流型对应的特征参数

Tab. 3 Characteristic parameters corresponding to three typical flow regimes in the trickle bed

流型	液相分数	液相分数	液相分数	半峰宽/%
	均值/ %	标准差/ %	极差/ %	
涓流 ($u_G = 0.069 \text{ m} \cdot \text{s}^{-1}$, $u_L = 0.003 \text{ m} \cdot \text{s}^{-1}$)	43.83	0.15	0.65	0.44

脉冲流	65.45	4.24	23.27	10.82
$(u_G = 0.069 \text{ m}\cdot\text{s}^{-1}, u_L = 0.022 \text{ m}\cdot\text{s}^{-1})$				
鼓泡流	82.93	3.37	24.61	7.20
$(u_G = 0.007 \text{ m}\cdot\text{s}^{-1}, u_L = 0.028 \text{ m}\cdot\text{s}^{-1})$				

采用基于深度学习的图像分析法得到 3 种典型流型下液相分数的均值、标准差、极差、概率密度分布曲线的半峰宽等特征参数，如表 3 所示。由表可知，不同流型下特征参数的数值差异明显，根据不同操作条件下特征参数的变化趋势，即可定量确定流型边界。

2.3 涓流床压降预测




图 9 涓流床压降的实验值与理论预测值的比较

Fig. 9 Comparison of the experimental pressure drop with theoretical predictions from the model in trickle flow.

Holub 等提出了一种涓流床压降的预测模型^[39]，如式（1）所示。式中， $\Delta P/Z$ 是单位床层压降， Ψ_G 为气相压降，床层空隙率 $\varepsilon_B=0.4$ ，液相分率 ε_L 通过图像分析方法得到， Re_G 和 G_{aG} 分别为气相雷诺数和伽利略数， E_1 和 E_2 是根据厄根公式修正而来的系数（根据文献^[40]，取 $E_1=180$ ， $E_2=1.8$ ）。气相密度 ρ_G 为 $1.185 \text{ kg}\cdot\text{m}^{-3}$ ，气相粘度 μ_G 为 $0.01834 \text{ mPa}\cdot\text{s}$ 。

$$\Psi_G = \frac{\Delta P / Z}{\rho_G g} + 1 = \left(\frac{\varepsilon_B}{\varepsilon_B - \varepsilon_L} \right)^3 \left[\frac{E_1 Re_G}{Ga_G} + \frac{E_2 Re_G^2}{Ga_G} \right] \quad (1)$$

在涓流床中的涓流区，基于图像分析方法在液速增加和减少的过程中得到了平均液相分数，代入式（1）计算得到床层压降随液速的变化曲线，其与液速上升和下降过程中 U 型管压差计测量值的比较如图 9 所示。可见，二者具有相同的变化趋势，平均相对偏差约为 15%。实验结果表明，本文提出的图像分析方法能够用于预测涓流床中涓流区的压降变化。

2.4 气液分布均匀性

采用本文提出的基于深度学习的图像分析方法，从原始图像提取气相分数和液相分数空

间分布的标准差,通过分析标准差的大小及其随时间的变化来判别气液分布的均匀性。涓流床中 3 种典型流型下局部液相分数空间分布的标准差随时间的变化如图 10 所示。从标准差的数值来看,涓流流型下标准差最大,对应的液相分率空间分布最不均匀;脉冲流下标准差次之;鼓泡流下标准差最小,对应的液相分率空间分布最均匀。从标准差随时间的变化来看,涓流流型下波动最小,脉冲流下波动居中,鼓泡流下波动最大。这是因为从脉冲流转变为鼓泡流后,床层空隙主要被液相占据,气泡随机向下流动,当气泡并聚或者大量气泡出现时,对气液两相的空间分布造成剧烈扰动,使得标准差波动增大。需要指出的是,如果拍摄区域不能覆盖整个床层截面,可将床层截面分为多个区域,用多个相机同时拍摄后,再使用上述方法判别气液分布均匀性。




图 10 涓流床中 3 种典型流型下局部液相分数空间分布的标准差随时间的变化

Fig. 10 Variation of the standard deviation of the spatial distribution of local liquid fractions under three typical flow regimes in the trickle bed

3 结论

本文发展了一种基于深度学习的气液固三相反应器图像分析方法,包括采集图像、制作训练集、建立图像识别模型和提取流动参数等四个步骤。其中,学习率、训练次数、训练集大小是采用全卷积神经网络模型建立的图像识别模型的关键参数。优选的模型参数为:学习率为 0.005,训练次数为 2000 次,训练集大小为超过 400 张图像。该方法可获取三相反应器中局部相含率(气相分数和液相分数)及其空间分布、时间序列等信息,采用时域分析、频率分析、小波分析等分析方法提取的二次参数,可用于流型识别、压降预测和气液分布的均匀性判别等。

本文将基于深度学习的图像分析方法用于气液并流向下涓流床中流动参数的检测,结果表明,局部液相分数随时间变化信号及其功率谱、概率密度分布曲线均能清晰地区分涓流、

脉冲流、鼓泡流等典型流型；均值、标准差、极差等特征参数随操作条件的变化趋势可用于确定流型边界；平均液相分数可用于预测涓流区压降，其与 U 型管压差计测量值的平均相对偏差约为 15%；液相分数空间分布的标准差可用于判别涓流床中不同流型下气液分布均匀性。

本文提出的图像分析方法只能测量气液固三相反应器壁面附近的流动参数，如何建立其与床层内部流动参数的关联，提高预测精度，有待深入研究。

参考文献

- [1] Nigam KDP, Larachi F. Process intensification in trickle-bed reactors[J]. Chemical Engineering Science. 2005, 60(22):5880-5894.
- [2] Kantarci N, Borak F, Ulgen KO. Bubble column reactors[J]. Process Biochemistry. 2005, 40(7):2263-2283.
- [3] Ng KM. A model for flow regime transitions in cocurrent down-flow trickle-bed reactors[J]. AIChE Journal. 1986, 32(1):115-122.
- [4] Ranade VV. Trickle Bed Reactors: Reactor Engineering and Applications[M]. Chaudhari RV. Amsterdam, The Netherlands: Elsevier, 2011:285.
- [5] Sai PST, Varma YBG. Flow pattern of the phases and liquid saturation in gas-liquid concurrent downflow through packed beds[J]. The Canadian Journal of Chemical Engineering. 1988, 66(3):353-360.
- [6] Sato Y, Hirose T, Takahashi F, et al. Flow pattern and pulsation properties of cocurrent gas-liquid downflow in packed beds. Journal of Chemical Engineering of Japan. 1973, 6(4):315-319.
- [7] Fukushima S, Kusaka K. Gas-liquid mass transfer and hydrodynamic flow region in packed columns with cocurrent upward flow[J]. Journal of Chemical Engineering of Japan. 1979, 12(4):296-301.
- [8] Melli TR, Desantos JM, Kolb WB, et al. Cocurrent downflow in networks of passages-microscale roots of macroscale flow regimes[J]. Industrial & Engineering Chemistry Research. 1990, 29(12):2367-2379.
- [9] Benkrid K, Rode S, Pons MN, et al. Bubble flow mechanisms in trickle beds - an experimental study using image processing[J]. Chemical Engineering Science. 2002, 57(16):3347-3358.
- [10] Jo D, Revankar ST. Bubble mechanisms and characteristics at pore scale in a packed-bed reactor[J]. Chemical Engineering Science. 2009, 64(13):3179-3187.
- [11] Gunjal PR, Kashid MN, Ranade VV, et al. Hydrodynamics of trickle-bed reactors: Experiments and CFD modeling[J]. Industrial & Engineering Chemistry Research. 2005, 44(16):6278-6294.
- [12] Urseanu MI, Boelhouwer JG, Bosman HJM, et al. Induced pulse operation of high-pressure trickle bed reactors

- with organic liquids: hydrodynamics and reaction study[J]. Chemical Engineering and Processing: Process Intensification. 2004, 43(11):1411-1416.
- [13] Kolb WB, Melli TR, Desantos JM, et al. Cocurrent downflow in packed beds. Flow regimes and their acoustic signatures[J]. Industrial & Engineering Chemistry Research. 1990, 29(12):2380-2389.
- [14] Boelhouwer JG, Piepers HW, Drinkenburg AAH. Nature and characteristics of pulsing flow in packed bed reactors[J]. Chemical Engineering Science. 2002, 57(22-23):4865-4876.
- [15] Zhao T, Eda T, Achyut S, et al. Investigation of pulsing flow regime transition and pulse characteristics in trickle-bed reactor by electrical resistance tomography[J]. Chemical Engineering Science. 2015, 130:8-17.
- [16] Singh BK, Jain E, Buwa VV. Feasibility of Electrical Resistance Tomography for measurements of liquid holdup distribution in a trickle bed reactor[J]. Chemical Engineering Journal. 2019, 358:564-579.
- [17] Basavaraj MG, Gupta GS, Naveen K, et al. Local liquid holdups and hysteresis in a 2-D packed bed using X-ray radiography[J]. AIChE Journal. 2005, 51(8):2178-2189.
- [18] Anadon LD, Sederman AJ, Gladden LF. Mechanism of the trickle-to-pulse flow transition in fixed-bed reactors[J]. AIChE Journal. 2006, 52(4):1522-1532.
- [19] Sederman AJ, Gladden LF. Transition to pulsing flow in trickle-bed reactors studied using MRI[J]. AIChE Journal. 2005, 51(2):615-621.
- [20] Hamidipour M, Larachi F, Ring Z. Cyclic operation strategies in trickle beds and electrical capacitance tomography imaging of filtration dynamics[J]. Industrial & Engineering Chemistry Research. 2010, 49(3):934-952.
- [21] Honda GS, Lehmann E, Hickman DA, et al. Effects of prewetting on bubbly- and pulsing-flow regime transitions in trickle-bed reactors[J]. Industrial & Engineering Chemistry Research. 2015, 54(42):10253-10259.
- [22] Schneider CA, Rasband WS, Eliceiri KW. NIH Image to ImageJ: 25 years of image analysis[J]. Nature Methods. 2012, 9(7):671-675.
- [23] LeCun Y, Bengio Y, Hinton G. Deep learning[J]. Nature. 2015, 521(7553):436-444.
- [24] Voulodimos A, Doulamis N, Doulamis A, et al. Deep learning for computer vision: A brief review[J]. Computational Intelligence and Neuroscience. 2018, 2018:1-13.
- [25] Schmidhuber J. Deep learning in neural networks: an overview[J]. Neural networks. 2015, 61:85-117.
- [26] Shaw GL. Donald Hebb: The Organization of Behavior[J]. Brain Theory, 1986, 17(3):231-233.
- [27] Arulkumaran K, Deisenroth MP, Brundage M, et al. Deep Reinforcement Learning A brief survey [J]. IEEE Signal Processing Magazine, 2017, 34(6):26-38.

- [28] Rumelhart DE, Hinton GE, Williams RJ. Learning representations by back-propagating errors[J]. *Nature*. 1986;323(6088):533-536.
- [29] Hinton GE, Osindero S, Teh YW. A fast learning algorithm for deep belief nets[J]. *Neural Computation*. 2006;18(7):1527-1554.
- [30] Ma RH, Zeng XQ. A Review of Deep Learning Research[J]. *KSII Transactions on Internet and Information Systems*. 2019;13(4):1738-1764.
- [31] Ciresan D, Meier U, Schmidhuber J. Multi-column deep neural networks for image classification[J]. *IEEE Conference on Computer Vision and Pattern Recognition*. 2012:3642-3649.
- [32] Litjens G, Kooi T, Bejnordi BE, et al. A survey on deep learning in medical image analysis[J]. *Medical Image Analysis*. 2017;42:60-88.
- [33] Taigman Y, Yang M, Ranzato MA, et al. DeepFace: Closing the gap to human-level performance in face verification[J]. *IEEE Conference on Computer Vision and Pattern Recognition*. 2014:1701-1708.
- [34] Ouyang W, Chu X, Wang X. Multi-source deep learning for human pose estimation[J]. *IEEE Conference on Computer Vision and Pattern Recognition*. 2014:2337-2344.
- [35] Paisitkriangkrai S, Sherrah J, Janney P, et al. Semantic labeling of aerial and satellite imagery[J]. *IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing*. 2016, 9(7):2868-2881.
- [36] Maggiori E, Tarabalka Y, Charpiat G, et al. Convolutional neural networks for large-scale remote-sensing image classification[J]. *IEEE Transactions on Geoscience and Remote Sensing*. 2017, 55(2):645-657.
- [37] Shelhamer E, Long J, Darrell T. Fully convolutional networks for semantic segmentation[J]. *IEEE Transactions on Pattern Analysis and Machine Intelligence*. 2017;39(4):640-651.
- [38] Levec J, Grosser K, Carbonell RG. The hysteretic behavior of pressure drop and liquid holdup in trickle beds[J]. *AIChE Journal*. 1988;34(6):1027-1030.
- [39] Holub RA, Dudukovic MP, Ramachandran PA. Pressure drop, liquid holdup, and flow regime transition in trickle flow[J]. *AIChE Journal*. 1993;39(2):302-321.
- [40] Macdonald IF, El-Sayed MS, Mow K, et al. Flow through Porous Media-the Ergun Equation Revisited[J]. *Industrial & Engineering Chemistry Fundamentals*, 1979, 18(3):199-208.